dplyr (continuación)

Entornos de Análisis de Datos: R

Alberto Torres

2020-02-02

Operaciones agrupadas

- La función `group_by()` convierte un data frame en otro agrupado por una o más variables.
- En los data frames agrupados todas las operaciones anteriores se realizan "por grupo".
- `ungroup()` elimina la agrupación.

Slice con group_by

- Los indices son relativos al grupo.

```
mpg %>%
  group_by(cyl) %>%
  slice(1:2)
## # A tibble: 8 x 11
## # Groups:   cyl [4]
##   manufacturer model          displ  year   cyl trans     drv     cty   hwy fl
##   <chr>        <chr>          <dbl> <int> <int> <chr>     <chr> <int> <int> <c
## 1 audi         a4               1.8  1999     4 auto(l5)  f        18    29 p
## 2 audi         a4               1.8  1999     4 manual(m~ f        21    29 p
## 3 volkswagen   jetta            2.5  2008     5 auto(s6)  f        21    29 r
## 4 volkswagen   jetta            2.5  2008     5 manual(m~ f        21    29 r
## 5 audi         a4               2.8  1999     6 auto(l5)  f        16    26 p
## 6 audi         a4               2.8  1999     6 manual(m~ f        18    26 p
## 7 audi         a6 quattro       4.2  2008     8 auto(s6)  4        16    23 p
## 8 chevrolet    c1500 suburban~  5.3  2008     8 auto(l4)  r        14    20 r
```

Select con group_by

- `select()` mantiene siempre las variables agrupadas, aunque no se indique explicitamente.

```
dim(mpg)
data <- mpg %>%
  group_by(cyl) %>%
  select(cty)
dim(data)
```

```
data <- mpg %>%
  group_by(cyl) %>%
  select(cty)
glimpse(data)
## Observations: 234
## Variables: 2
## Groups: cyl [4]
## $ cyl <int> 4, 4, 4, 4, 6, 6, 6, 4, 4, 4, 4, 6, 6, 6, 6, 6, 6, 8, 8, 8, 8, 8, 8
## $ cty <int> 18, 21, 20, 21, 16, 18, 18, 18, 16, 20, 19, 15, 17, 17, 15, 15, 17,
```

arrange con group_by

- `arrange()` ordena por la(s) variable(s) especificadas como parámetros.

```
data <- mpg %>%
  group_by(cyl) %>%
  arrange(manufacturer)
glimpse(data)
## Observations: 234
## Variables: 11
## Groups: cyl [4]
## $ manufacturer <chr> "audi", "audi", "audi", "audi", "audi", "audi", "audi", "a
## $ model        <chr> "a4", "a4", "a4", "a4", "a4", "a4", "a4", "a4 quattro", "a
## $ displ        <dbl> 1.8, 1.8, 2.0, 2.0, 2.8, 2.8, 3.1, 1.8, 1.8, 2.0, 2.0, 2.8
## $ year         <int> 1999, 1999, 2008, 2008, 1999, 1999, 2008, 1999, 1999, 2008
## $ cyl          <int> 4, 4, 4, 4, 6, 6, 6, 4, 4, 4, 4, 6, 6, 6, 6, 6, 6, 8, 8, 8
## $ trans        <chr> "auto(l5)", "manual(m5)", "manual(m6)", "auto(av)", "auto(
## $ drv          <chr> "f", "f", "f", "f", "f", "f", "f", "4", "4", "4", "4", "4"
## $ cty          <int> 18, 21, 20, 21, 16, 18, 18, 18, 16, 20, 19, 15, 17, 17, 15
## $ hwy          <int> 29, 29, 31, 30, 26, 26, 27, 26, 25, 28, 27, 25, 25, 25, 25
## $ fl           <chr> "p", "p", "p", "p", "p", "p", "p", "p", "p", "p", "p", "p"
## $ class        <chr> "compact", "compact", "compact", "compact", "compact", "co
```

summarize con group_by

Un `summarize()` sobre un data frame agrupado devuelve otro con tantas filas como grupos (valores distintos de la/s variable/s usadas para agrupar).

```
mpg %>%
  group_by(cyl) %>%
  summarize(avg_cty = mean(cty))
## # A tibble: 4 x 2
##     cyl avg_cty
##   <int>   <dbl>
## 1     4    21.0
## 2     5    20.5
## 3     6    16.2
## 4     8    12.6
```

Metodología split-apply-combine

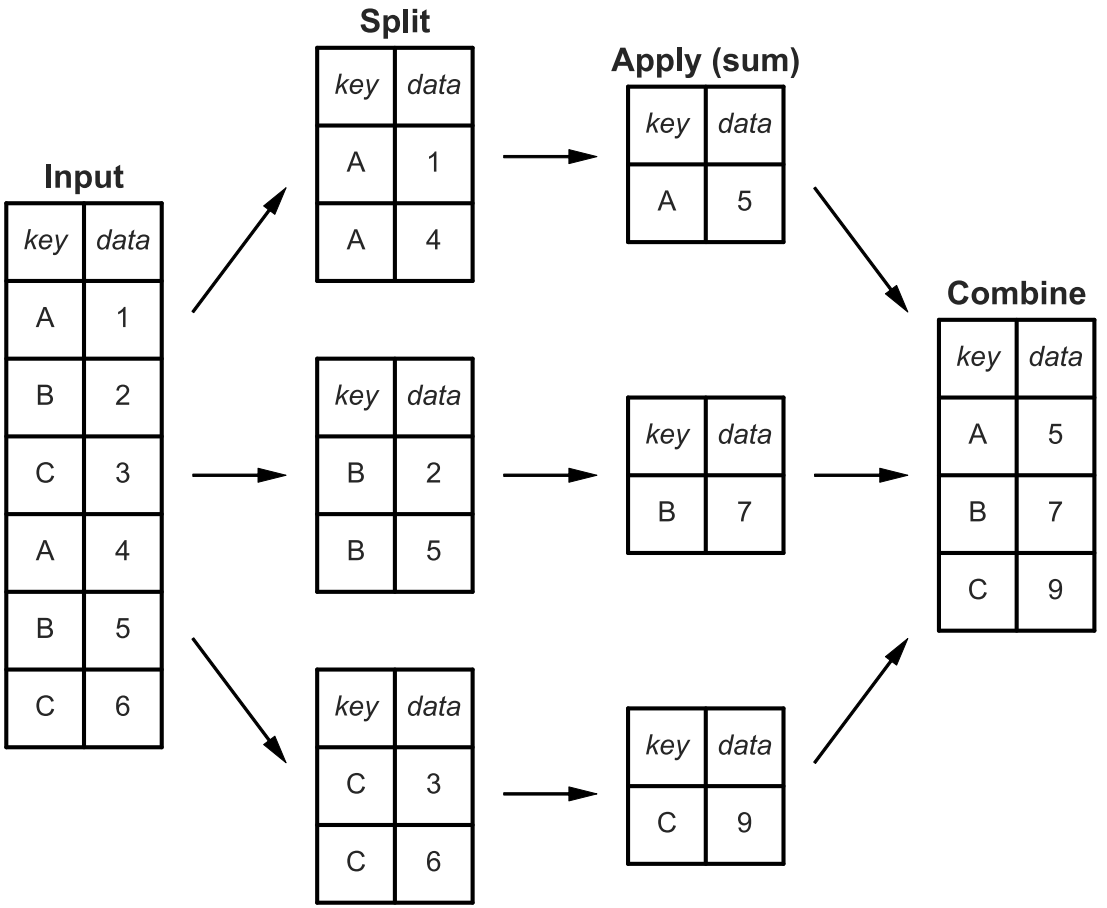

mutate con group_by

Un `mutate()` sobre un data frame agrupado devuelve siempre otro data frame con el mismo número de filas que el original.

```
data <- mpg %>%
  group_by(cyl) %>%
  mutate(avg_cty = mean(cty))
glimpse(data)
## Observations: 234
## Variables: 12
## Groups: cyl [4]
## $ manufacturer <chr> "audi", "audi", "audi", "audi", "audi", "audi", "audi", "a
## $ model        <chr> "a4", "a4", "a4", "a4", "a4", "a4", "a4", "a4 quattro", "a
## $ displ        <dbl> 1.8, 1.8, 2.0, 2.0, 2.8, 2.8, 3.1, 1.8, 1.8, 2.0, 2.0, 2.8
## $ year         <int> 1999, 1999, 2008, 2008, 1999, 1999, 2008, 1999, 1999, 2008
## $ cyl          <int> 4, 4, 4, 4, 6, 6, 6, 4, 4, 4, 4, 6, 6, 6, 6, 6, 6, 8, 8, 8
## $ trans        <chr> "auto(l5)", "manual(m5)", "manual(m6)", "auto(av)", "auto(
## $ drv          <chr> "f", "f", "f", "f", "f", "f", "f", "4", "4", "4", "4", "4"
## $ cty          <int> 18, 21, 20, 21, 16, 18, 18, 18, 16, 20, 19, 15, 17, 17, 15
## $ hwy          <int> 29, 29, 31, 30, 26, 26, 27, 26, 25, 28, 27, 25, 25, 25, 25
## $ fl           <chr> "p", "p", "p", "p", "p", "p", "p", "p", "p", "p", "p", "p"
## $ class        <chr> "compact", "compact", "compact", "compact", "compact", "co
## $ avg_cty      <dbl> 21.01235, 21.01235, 21.01235, 21.01235, 16.21519, 16.21519
```

joins

- La librería `dplyr` implementa funciones para unir data frames:
  - `inner_join(x,y)` : Devuelve las filas que crucen tant en x como en y.
  - `left_join(x,y)` : Devuelve todas, las filas en x y las que crucen en y (completa con NA)
  - `right_join(x,y)` : Devuelve todas las filas en y y las que crucen en x (completa con NA).
  - `full_join(x,y)` : Devuelve todas las filas de x e y (completa con NA).
  - `semi_join(x,y)` : Devuelve solo las filas de x que crucen con y (pero no y).
  - `anti_join(x,y)` : Devuelve solo las filas de x que NO crucen con y.
- Diagrama de Venn [R for Data Science]

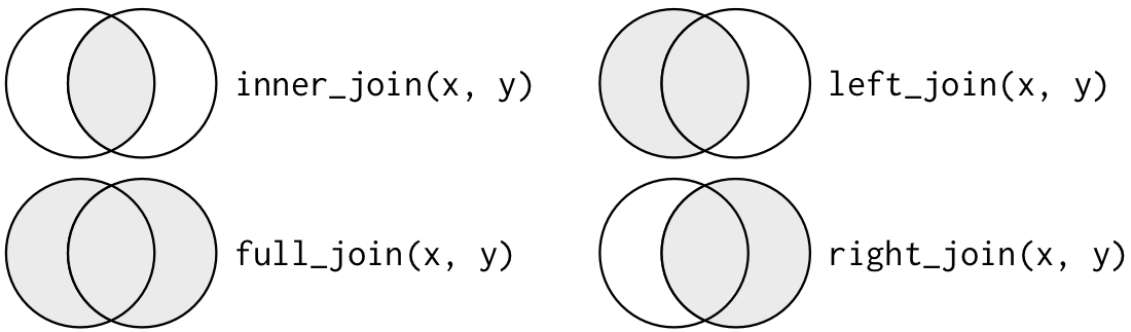

Equivalencia con SQL

dplyr	SQL
`inner_join(x, y, by = "z")`	`SELECT * FROM x INNER JOIN y USING (z)`
`left_join(x, y, by = "z")`	`SELECT * FROM x LEFT OUTER JOIN y USING (z)`
`right_join(x, y, by = "z")`	`SELECT * FROM x RIGHT OUTER JOIN y USING (z)`
`full_join(x, y, by = "z")`	`SELECT * FROM x FULL OUTER JOIN y USING (z)`

[R for Data Science]

Ejemplo

```
t4a <- gather(table4a, key = "year", value = "cases", num_range("", 1999:2000))
head(t4a,4)
## # A tibble: 4 x 3
##   country     year   cases
##   <chr>       <chr>  <int>
## 1 Afghanistan 1999     745
## 2 Brazil      1999   37737
## 3 China       1999  212258
## 4 Afghanistan 2000    2666
t4b <- gather(table4b, key = "YEAR", value = "population", `1999`:`2000`)
head(t4b,4)
## # A tibble: 4 x 3
##   country     YEAR  population
##   <chr>       <chr>      <int>
## 1 Afghanistan 1999    19987071
## 2 Brazil      1999   172006362
## 3 China       1999  1272915272
## 4 Afghanistan 2000    20595360
```

Ejemplo (cont.)

```
inner_join(t4a, t4b, by=c("year" = "YEAR", "country"))
## # A tibble: 6 x 4
##   country     year   cases population
##   <chr>       <chr>  <int>      <int>
## 1 Afghanistan 1999     745   19987071
## 2 Brazil      1999   37737  172006362
## 3 China       1999  212258 1272915272
## 4 Afghanistan 2000    2666   20595360
## 5 Brazil      2000   80488  174504898
## 6 China       2000  213766 1280428583
```

Operaciones de conjuntos con dplyr

- `dplyr` implementa la lógica de operaciones con conjuntos sobre tibbles.
  - `intersect(x,y)` : Filas que aparecen tanto en x como en y.
  - `union(x,y)` : Filas que aparecen en x, en y, o en ambos.
  - `setdiff(x,y)` : Filas que aparecen en x, pero no en y.

```
x <- tibble(
  x1=c("A","B","C"),
  x2=1:3
)
y <- tibble(
  x1=c("B","C","D"),
  x2=2:4
)
dplyr::intersect(x,y)
dplyr::union(x,y)
dplyr::setdiff(x,y)
```

Añadir filas y/o columnas en dplyr

- `dplyr` implementa las funciones `bind_rows` y `bind_cols` para añadir filas o columnas a un tibble, respectivamente.
- Las funciones de `dplyr` son **más eficientes** que las funciones `rbind` y `cbind` de R base.
- En `bind_rows` las columnas se combinan por nombre y las columnas que no están en alguno de los dataframes se rellenan con NAs.

```
bind_rows(
  c(a = 1, b = 2),
  tibble(saludo="hola", a = 3:4, b = 5:6),
  c(a = 7, b = 8)
)
## # A tibble: 4 x 3
##       a     b saludo
##   <dbl> <dbl> <chr>
## 1     1     2 <NA>
## 2     3     5 hola
## 3     4     6 hola
## 4     7     8 <NA>
```

Añadir filas y/o columnas en dplyr (cont.)

- En `bind_cols` se unen las subtablas por posición -> todos los dataframes deben tener el mismo número de filas.
  - Para unir por valores, usar `join`.

```
# Both have to be tibbles
bind_cols(
  tibble(a = 3:4, b = c("a", "b")),
  tibble(logical = c(T, F))
)
## # A tibble: 2 x 3
##       a b     logical
##   <int> <chr> <lgl>
## 1     3 a     TRUE
## 2     4 b     FALSE
```

Operar en múltiples columnas

- dplyr tiene variantes de sus funciones principales que operan sobre múltiples columnas
- La selección de columnas puede ser:
  - Todas, funciones que terminan en `_all`
  - Con un predicado, funciones que terminan en `_if`
  - Vector con nombres, posiciones o función `vars()`

```
summarize_all(mpg, funs(sum(is.na(.))))
## # A tibble: 1 x 11
##   manufacturer model displ  year   cyl trans   drv   cty   hwy    fl class
##          <int> <int> <int> <int> <int> <int> <int> <int> <int> <int> <int>
## 1            0     0     0     0     0     0     0     0     0     0     0
```

```
mutate_if(mpg, is.numeric, log)
## # A tibble: 234 x 11
##    manufacturer model      displ  year   cyl trans      drv     cty   hwy fl
##    <chr>        <chr>      <dbl> <dbl> <dbl> <chr>      <chr> <dbl> <dbl> <chr>
##  1 audi         a4         0.588  7.60  1.39 auto(l5)   f      2.89  3.37 p
##  2 audi         a4         0.588  7.60  1.39 manual(m5) f      3.04  3.37 p
##  3 audi         a4         0.693  7.60  1.39 manual(m6) f      3.00  3.43 p
##  4 audi         a4         0.693  7.60  1.39 auto(av)   f      3.04  3.40 p
##  5 audi         a4         1.03   7.60  1.79 auto(l5)   f      2.77  3.26 p
##  6 audi         a4         1.03   7.60  1.79 manual(m5) f      2.89  3.26 p
##  7 audi         a4         1.13   7.60  1.79 auto(av)   f      2.89  3.30 p
##  8 audi         a4 quattro 0.588  7.60  1.39 manual(m5) 4      2.89  3.26 p
##  9 audi         a4 quattro 0.588  7.60  1.39 auto(l5)   4      2.77  3.22 p
## 10 audi         a4 quattro 0.693  7.60  1.39 manual(m6) 4      3.00  3.33 p
## # ... with 224 more rows
```